Untersuchung von splicing RNAs(splRNA), die an einem Protein *AGSP7* binden.

Fachbereich:

Mathematik, Naturwissenschaften und Informatik (**MNI**)
an der Technischen Hochschule Mittelhessen

Studiengang:

Bioinformatik (B.Sc.)

von

Zidane Soreil Kuissu Youmbi

Gießen, 8. März 2026

Inhaltsverzeichnis

1 Adapter entfernen **2**

2 Mapping der Reads gegen das Genom **2**

2.1 bowtie2 hochladen und index bauen: 2

2.2 Mappen: 2

2.3 SAM-datein zu BAM-datein[4] 3

3 AGSP7-Bindungsmotiv: **3**

4 Identifikation von splRNAs **3**

4.1 Richtigen Strang 3

4.2 Filtierung der Reads um splRNA zu identifizieren 4

4.3 Anzahl der splRNAs in den Daten 5

4.4 interpretation 6

5 Alternative Spleißen Untersuchung **6**

5.1 Optionalen Exons identifizieren 6

5.2 Referenzen bauen: Verhältnis von Splice-in und Splice-out ableiten und berechnen 6

6 splRNA in der Nähe von Optional-exon prüfen, splRNA-Häufigkeit-korrelation und Scatterplot **8**

6.1 splRNA in der Nähe von Optional-exon prüfen 8

6.2 splRNA-Häufigkeit-korrelation 8

6.3 Scatterplot 8

6.4 interpretation 9

7 Beschreibung und Schlussfolgerung **9**

1 Adapter entfernen

Mit dem Script **(adapter_removal.ipynb)** kann man die Adapter [2]in die KO-Datensatz und WT-Datensatz entfernen.

```
# Siehe adapter_removal.ipynb
    adapter_entfern("AGSP7_KO_RIP-Seq.fastq", "KO_ohneAdapter.fastq",
        "AGATCGGAAGAGCACACGTCTGAACTCCAGTCA")
    adapter_entfern("AGSP7_WT_RIP-Seq.fastq", "WT_ohneAdapter.fastq",
        "AGATCGGAAGAGCACACGTCTGAACTCCAGTCA")
```

2 Mapping der Reads gegen das Genom

Wir haben bereits Informationen über die Länge der **splRNAs**, die sind **60-100nt** lang. Sie bestehen auch aus zwei Teilen, die an unterschiedlichen Stellen der Prä-RNA binden.
Um das mapping durchführen zu können, entscheide ich mich für **Bowtie2** [3]als Tools zu nützen.

2.1 bowtie2 hochladen und index bauen:

```
cd ~
mkdir -p tools
cd tools
wget https://sourceforge.net/projects/bowtie-bio/files/bowtie2/2.5.3/
# datein entpacken
unzip bowtie2-2.5.3-linux-x86_64.zip
# Bowtie2 in PATH eintragen:
export PATH=$HOME/tools/bowtie2-2.5.3-linux-x86_64:$PATH
# bowtie2 index bauen:
bowtie2-build ./hg38.fa hg38_index
```

2.2 Mappen:

- WT-ohneAdapter.fastq

```
bowtie2 -x hg38_index -U WT_ohneAdapter.fastq -S WT_mapped.sam \
--very-sensitive-local -p 8 2> WT_mapped.log
```

- KO-ohneAdapter.fastq

```
bowtie2 -x hg38_index -U KO_ohneAdapter.fastq -S KO_mapped.sam \
--very-sensitive-local -p 8 2> KO_mapped.log
```

2.3 SAM-datein zu BAM-datein[4]

- WT-ohneAdapter.fastq

```
samtools view -bS WT_mapped.sam > WT_mapped.bam
samtools sort WT_mapped.bam -o WT_mapped.sorted.bam
samtools index WT_mapped.sorted.bam
```

- KO-ohneAdapter.fastq

```
samtools view -bS KO_mapped.sam > KO_mapped.bam
samtools sort KO_mapped.bam -o KO_mapped.sorted.bam
samtools index KO_mapped.sorted.bam
```

3 AGSP7-Bindungsmotiv:

Mit dem Script **(agsp7_binding_motif.ipynb)** kann man die AGSP7-Bindungmotiv finden, indem man die häufigsten K-Mer suchen untersucht.

```
    # Siehe agsp7_binding_motif.ipynb
find_bindenstelle(seq, 6)
[('ACTTTG',13), ('CTTTGT',13), ('TTTTTT',10), ('TTTGTT',6), ('GACTTT',6)]
```

Also wir werden in den nächste Schritte der Arbeit **ACTTTG** als AGSP7-Bindungsmotiv betrachten

4 Identifikation von splRNAs

Ein **RNA** ist als ***splicing RNA(splRNA)*** identifiziert, wenn es (a) auf dem *richtigen Strang* liegt und (b) wenn es *innerhalb eines Gens* liegt.

4.1 Richtigen Strang

Nachdem wir gemappt haben, können wir featureCounts nutzen, um den **richtigen Strang** zu bestimmen:
Legolas sagt: Die Reads sind *Strangspezifisch* und die Tatsache, dass eine splRNA an ein Prä-RNA bindet, bedeutet, dass die splRNA die reversen Komplement der

Prä-RNA enthält.
Laut der featureCounts Dokumentation[5], welcher die meisten Assigned reads hat, ist für die Richtung entscheidend: **-s 1**: forward stranded, **-s 2**: reverse stranded

```
# FeaturesCounts zu prüfen.
./subread-2.0.6-source/bin/featureCounts \
-T 8 -s 1 -a ./hg38.ncbiRefSeq.gtf \
-o counts_s1.txt WT_mapped_sorted.bam # Assigned reads= 658959

./subread-2.0.6-source/bin/featureCounts \
-T 8 -s 2 -a ./hg38.ncbiRefSeq.gtf \
-o counts_s2.txt WT_mapped_sorted.bam # Assigned reads= 5445257
```

Also Library (Stranded Total RNA) ist **reverse stranded**, splRNA enthält reverse komplementär der prä-mRNA. prä-mRNA liegt auf dem Gen-Strang, das heißt: Wenn ein Gen auf + liegt, prä-mRNA ist auf +, splRNA ist reverse komplementär also **-**, aber da Library reverse stranded ist, ist Read wieder reversed und mappt der Read wieder auf +.
Bei reverse stranded gilt:**splRNA-Strang = Gen-Strang**, das ist der **RICHTIGE Strang**.

4.2 Filtierung der Reads um splRNA zu identifizieren

Ein **splRNA** ist laut der Definition nicht komplett gemappt, also es enthält **Soft-Clipping(S)**, enthält zwischen **60 und 100 nt**, liegt innerhalb eines Gens(**intons**) und in der richtige Strang.

- **filtierung nach Soft-Clipping**

  ```
  samtools view -h WT_mapped_sorted.bam | \
  awk '$1 ~ /^@/ || $6 ~ /S/ || $6 ~ /[0-9]+M.*S.*[0-9]+M/' \
  > WT_splRNAnouvo.sam
  samtools view -h KO_mapped_sorted.bam | \
  awk '$1 ~ /^@/ || $6 ~ /S/ || $6 ~ /[0-9]+M.*S.*[0-9]+M/' \
  > KO_splRNAnouvo.sam
  ```

- **intron Bereiche definieren**

  ```
  # transcript bzw. gene definieren:
  awk '$3=="transcript"' hg38.ncbiRefSeq.gtf | \
  awk '{print $1"\t"$4-1"\t"$5"\t"$10"\t.\t"$7}' | \
  ```

```
sed 's/"//g;s/;//g' > genes.bed
# exons definieren:
awk '$3=="exon"' hg38.ncbiRefSeq.gtf | \
awk 'BEGIN{OFS="\t"} {print $1, $4-1, $5, $10, ".", $7}' | \
sed 's/"//g;s/;//g' > exons.bed
#dabei auch introns definieren
bedtools subtract -a genes.bed -b exons.bed -s > introns.bed
```

- **SAM-datein nach Bindungsmotiv filtern und zu BED-datein umwandeln**[6]

```
samtools view -H WT_splRNAnouvo.sam > WTheader.sam
grep "ACTTTG" WT_splRNAnouvo.sam > WT_reads.sam # alternative: "CTTTGT"
cat WTheader.sam WT_reads.sam > WT_bestesplRNA_withHeader.sam
samtools view -bS WT_bestesplRNA_withHeader.sam > WT_bestesplRNA.bam
bedtools bamtobed -i WT_bestesplRNA.bam > WT_bestesplRNA.bed

samtools view -H KO_splRNAnouvo.sam > KOheader.sam
grep "ACTTTG" KO_splRNAnouvo.sam > KO_reads.sam # alternative: "CTTTGT"
cat KOheader.sam KO_reads.sam > KO_bestesplRNA_withHeader.sam
samtools view -bS KO_bestesplRNA_withHeader.sam > KO_bestesplRNA.bam
bedtools bamtobed -i KO_bestesplRNA.bam > KO_bestesplRNA.bed
```

- **splRNA, die auf Genome liegen herausfiltern.**

```
bedtools intersect -a WT_bestesplRNA.bed -b introns.bed -wa -wb \
> WT_bestesplRNA_in_genes_intron.bed
bedtools intersect -a KO_bestesplRNA.bed -b introns.bed -wa -wb \
> KO_bestesplRNA_in_genes_intron.bed

awk '$6==$12' WT_bestesplRNA_in_genes_intron.bed \
> WT_bestesplRNA_endlichintron.bed
awk '$6==$12' KO_bestesplRNA_in_genes_intron.bed \
> KO_bestesplRNA_endlichintron.bed
```

4.3 Anzahl der splRNAs in den Daten

```
cut -f1-6 WT_bestesplRNA_endlichintron.bed | sort | uniq > WT_monsplRNA.bed
wc -l WT_monsplRNA.bed
    # Anzahl der splRNA in WT_Daten= 27686 (29225)
```

```
cut -f1-6 KO_bestesplRNA_endlichintron.bed | sort | uniq > KO_monsplRNA.bed
wc -l KO_monsplRNA.bed
    # Anzahl der splRNA in KO_Daten= 5010 (6663)
```

4.4 interpretation

Im **WT-Datensatz** wurden deutlich mehr splRNA-Kandidaten**(ca. 27686)** identifiziert als im **KO-Datensatz (ca. 5010)** (5-facher Unterschied). Die intronische Lokalisation entspricht der Hypothese, dass splRNAs an Prä-mRNA binden. Die Strangorientierung bestätigt, dass die Reads reverse komplementär zur Ziel-Prä-mRNA sind. Die deutliche Reduktion im KO spricht dafür, dass der SPLRPF-Knockout die splRNA-Bildung effektiv beeinflusst hat.

5 Alternative Spleißen Untersuchung

5.1 Optionalen Exons identifizieren

Optionalen Exons sind Exons, die in einigen, aber nicht allen Isoformen des Gens enthalten sind. Um diese in Geneannotation zu identifieren, gilt den **(optional_exons_analysis.ipynb)** Script.

5.2 Referenzen bauen: Verhältnis von Splice-in und Splice-out ableiten und berechnen

Splice-in: ist eine *Inclusion* von Optionalen-exons in den Isoformen des Gens.
Splice-out: Skipping, ist ein *Exclusion* von Optionalen-exons in Isoformen des Gens.
Bevor wir die Referenzen bauen, müssen wir nochmal aber mit **STAR** die Datensätzen mappen um den **SJ.out.tab-Datein** zu haben. Damit kann man gut den Splicingfaktor(**PSI: *Perzent Splicing In***) berechnen.

```
# STAR auf dem server hochladen
# 1) herunterladen
wget https://github.com/alexdobin/STAR/archive/refs/tags/2.7.11b.tar.gz
# 2) entpacken
tar -xvzf 2.7.11b.tar.gz
# 3) ins Verzeichnis wechseln
cd STAR-2.7.11b/source
```

```
# 4) Kompilieren
make STAR

    # index bauen
./STAR-2.7.11b/source/STAR --runThreadN 8 \
--runMode genomeGenerate --genomeDir ./star_index \
--genomeFastaFiles ./hg38.fa --sjdbGTFfile ./hg38.ncbiRefSeq.gtf \
--sjdbOverhang 100

    # Mappen
./STAR-2.7.11b/source/STAR --runThreadN 8 \
--genomeDir ./star_index --readFilesIn ./KO_ohneAdapter.fastq \
--outFileNamePrefix ./KO_ --outSAMtype BAM SortedByCoordinate

./STAR-2.7.11b/source/STAR --runThreadN 8 \
--genomeDir ./star_index --readFilesIn ./WT_ohneAdapter.fastq \
--outFileNamePrefix ./WT_ --outSAMtype BAM SortedByCoordinate
```

Das Verhältnis von Splice-in und Splice-out(Die beide Referenzen) lässt sich gut mit einem Script **(reference_ratio.ipynb)**ableiten.
Es wird ein Datein *PSI_WT_vs_KO_filtered.csv* erzeugt, wobei **gene, exon_start, exon_end, PSI_WT, PSI_KO und ΔPS** gespeichert wurden

6 splRNA in der Nähe von Optional-exon prüfen, splRNA-Häufigkeit-korrelation und Scatterplot

6.1 splRNA in der Nähe von Optional-exon prüfen

```
bedtools window -a optional_exons.bed -b WT_monsplRNA.bed -w 250 > WT_near_250.bed
cut -f1-6 WT_near_250.bed | sort | uniq | wc -l # 5554
bedtools window -a optional_exons.bed -b KO_monsplRNA.bed -w 250 > KO_near_250.bed
cut -f1-6 KO_near_250.bed | sort | uniq | wc -l # 978
```

In der Nähe von Optionalen-Exons binden **5554** splRNA für WT und **978** für KO.

6.2 splRNA-Häufigkeit-korrelation

Die Korrelation zwischen splRNA-Häufigkeit um den Alternative Splicing zu beweisen, lässt sich wie folgendes erstellen:

```
sort -k1,1 -k2,2n WT_monsplRNA.bed > WT_monsplRNA.sorted.bed
sort -k1,1 -k2,2n delta_PSI_exons.bed > delta_PSI_exons.sorted.bed
bedtools closest -a delta_PSI_exons.sorted.bed \
-b WT_monsplRNA.sorted.bed -d > exon_splRNA_distance.txt
awk '$NF < 250' exon_splRNA_distance.txt > exon_splRNA_near.txt
```

Idee dahinter is zu jedes Delta-PSI-exon von **delta_PSI_exons.bed** (*erzeugt mit* ***correlation_analysis.ipynb***) ein Abstand zur nächsten splRNA zu berechnen

6.3 Scatterplot

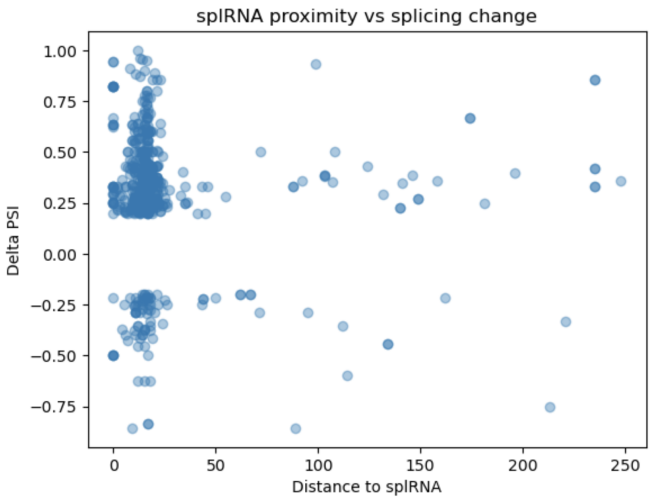

Abbildung 1: **Distance zu splRNA vs Delta PSI**

6.4 interpretation

Exons mit starken Veränderungen im Spleißen (hoher ΔPSI-Wert) befinden sich häufig in der Nähe von splRNA-Bindungsstellen. Dies deutet darauf hin, dass splRNAs die Aktivität des Spliceosoms lokal beeinflussen und dadurch das Einfügen oder Überspringen von Exons fördern können. Das Verschwinden dieses Zusammenhangs im SPLRPF-Knockout unterstützt zusätzlich die Annahme, dass splRNAs eine funktionelle Rolle bei der Regulation des alternativen Spleißens spielen.

7 Beschreibung und Schlussfolgerung

Nach Adapter_Trimming und Mapping gegen **Hg38-genome** wurden Reads gefunden die: **nicht vollständig mappen(*Soft-Clipping*); innerhalb von Genregionen(Introns)liegen; auf dem entgegengesetzten Strang der Gene und den Motiv(*ACTTTG*) enthalten.**
Es gab viele **splRNAs** in WT-Datensatz **(27686 bzw. 29225)**, aber sehr wenig in KO-Datensatz **(5010 bzw. 6663)**. Also im KO war der *SPLRPF-Knockout Experimente* erfolgreich.
Um die Analyse von **Alternative Splicing**, wurde die Optionale Exons definiert, das Verhältnis von Splice-In und Splice-Out durch **PSI(Percent Splicing In)** berechnet und den Zusammenhang zwischen splRNAs, deren Position in Genome und die alternativem Splicing evaluiert.
Für optional Exons würde die PSI berechnet:

$$PSI = \frac{inclusion}{inclusion + skipping}$$

Je größer ist die PSI, desto warhscheinlischer ist die Exon inkludiert. Je größer ist die Änderung der PSI:

$$\Delta PSI = PSI_{WT} - PSI_{KO}$$

desto mehr es **Splicing-veränderungen** gibt.
Für den Zusammenhang zwischen splRNAs, deren Position in Genome und die alternativem Splicing wurde beobachtet, dass von **251625 Optional-Exons** nur **5554(2.2%)** liegen generell in der Nähe einer splRNA. Aber bei ΔPSI-Exons **637 von 4311(14.8%)** liegen nahe einer splRNA. Exons mit verändertem Splicing sind viel **häufiger nahe einer splRNA**. Das deutet darauf hin, dass **splRNAs alternative splicing regulieren**.

Analyse	WT_Datenastz	KO_Datensatz
BindungsMotiv	ACTTTG	ACTTTG
Anzahl der splRNA	27686	5010
Optionalen_Exons	251625	251625
Exons nahe von splRNA(250nt)	5554	978
*Delta*PSI_Exons nahe von splRNA	637	53

Die Analyse der RIP-Seq Daten zeigt: Es existieren splRNAs, die an AGSP7 binden. Diese splRNAs enthalten Sequenzen Komplementär zu Prä-RNAs, binden innerhalb von Genregionen. splRNAs sind im SPLRPF Knockout stark reduziert, was daraufhinweist, dass dieser Faktor für ihre Biogenese notwendig ist. Exons mit verändertem splicing sing signifikant häufiger in der Nähe von splRNAs, aber diese Beziehung verschwindet im KO-Datensatz.

Literatur

[1] R. Henschel. *Bioinformatics Notebook: Sequence Alignment and Processing*. 2020. URL: https://rnnh.github.io.

[2] Illumina, Inc. *Illumina Adapter Sequences*. Dokument-Nr. 1000000002694 v20. Illumina, Inc. San Diego, CA, 2025. URL: https://support-docs.illumina.com.

[3] Ben Langmead und Steven L. Salzberg. „Fast gapped-read alignment with Bowtie 2“. In: *Nature Methods* 9.4 (2012), S. 357–359. DOI: 10.1038/nmeth.1923. URL: https://bowtie-bio.sourceforge.net.

[4] Heng Li u. a. „The Sequence Alignment/Map format and SAMtools“. In: *Bioinformatics* 25.16 (2009), S. 2078–2079. DOI: 10.1093/bioinformatics/btp352. URL: https://www.htslib.org.

[5] Yang Liao, Gordon K. Smyth und Wei Shi. „The R package Rsubread is easier, faster, cheaper and better for alignment and quantification of RNA sequencing reads“. In: *Nucleic Acids Research* 47.8 (2019), e47. DOI: 10.1093/nar/gkz114. URL: https://bioconductor.org.

[6] Aaron R. Quinlan und Ira M. Hall. „BEDTools: a flexible suite of utilities for comparing genomic features“. In: *Bioinformatics* 26.6 (2010), S. 841–842. DOI: 10.1093/bioinformatics/btq033. URL: https://bedtools.readthedocs.io.